

配信基盤リアーキテクチャ 技術選定レポート

現行の配信基盤は単一リージョン構成で、ピーク時のレイテンシ悪化と、障害時の影響範囲の広さが課題となっている。本レポートでは次期基盤の構成候補を比較し、採用方針を整理する。

Note

本レポートは社内検討用のドラフトです。数値は 2026 年 Q1 時点の実測値およびベンダー公称値に基づきます。

評価の観点

次の 4 点を重み付けして評価した。

- レイテンシ — p95 応答時間
- 可用性 — SLA と障害分離
- 運用コスト — 月額ランニング
- 移行容易性 — 既存コードの改修量

構成候補の比較

構成	p95 (ms)	可用性	月額 (千円)	移行 (人日)
現行 (単一リージョン)	420	99.5%	180	—
マルチリージョン Active-Active	180	99.99%	540	45
エッジキャッシュ + 単一オリジン	150	99.9%	320	20

エッジキャッシュ構成が、レイテンシと移行工数のバランスで最も優れる¹。

Warning

マルチリージョン Active-Active はデータ整合性の設計が複雑で、結果整合性を許容できない一部の機能とは相性が悪い。

移行イメージ

エッジ層のルーティングは、オリジンへのフォールバック付きキャッシュとして実装する。

```
// edge/router.ts
export async function handle(req: Request): Promise<Response> {
  const cached = await cache.match(req)
  if (cached) return cached

  const res = await fetch(originFor(req), { cf: { cacheTtl: 300 } })
  if (res.ok) await cache.put(req, res.clone())
  return res
}
```

💡 Tip

キャッシュ TTL は機能ごとに調整できる。更新頻度の低い静的メタデータは長め（1 時間）に設定すると、オリジン負荷をさらに下げられる。

推奨

- **短期:** エッジキャッシュ + 単一オリジンを採用し、p95 を 150ms 帯へ
- **中期:** トラフィック増を見て Active-Active を再評価する

移行は 2026 年 Q2 着手、Q3 完了を目標とする²。

pdfmint で Markdown から生成 (`--preset report`)

1. 移行工数は既存ルーティング層の抽象度に依存する。本見積もりは現行コードの調査に基づく概算。↩
2. 詳細スケジュールは別紙のロードマップを参照。↩